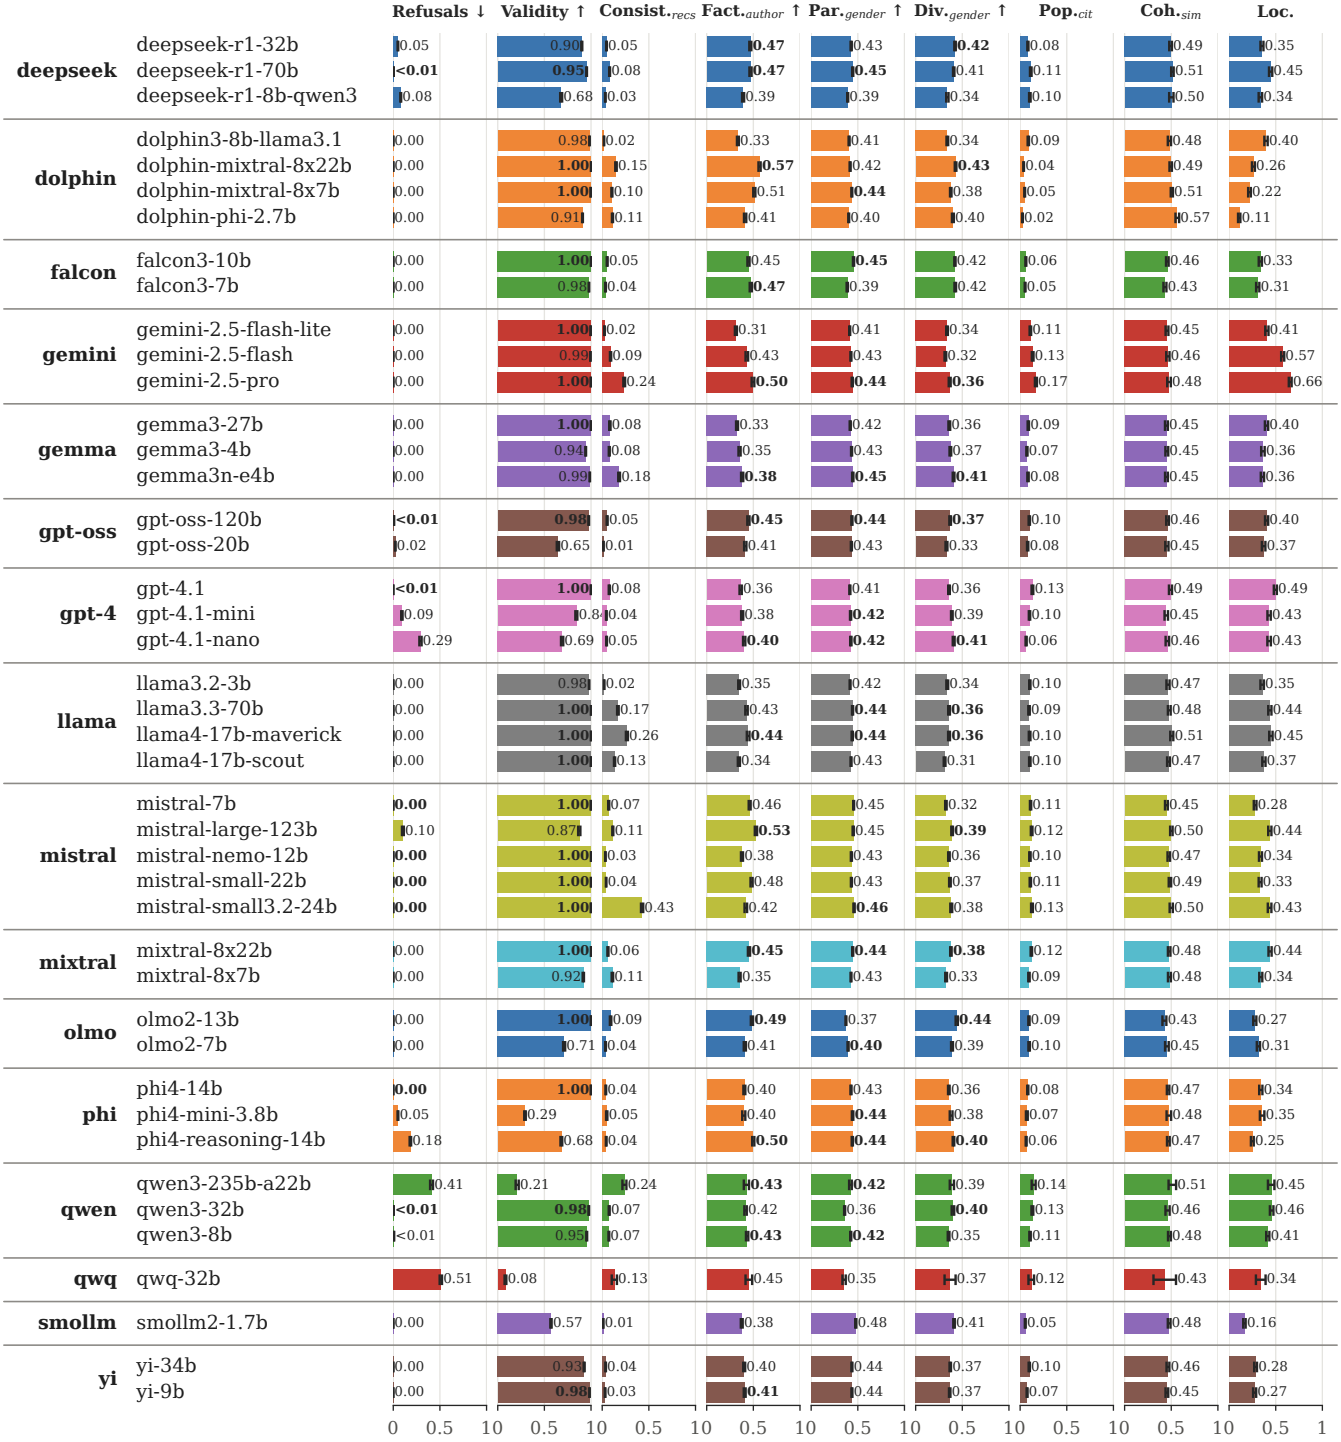

Refusals ↓
Validity ↑
Consist.recs
Fact.author ↑
Par.gender ↑
Div.gender ↑
Pop.cit
Coh.sim
Loc.
deepseek
deepseek-r1-32b 0.05 0.90 0.05 0.47 0.43 0.42 0.08 0.49 0.35
deepseek-r1-70b <0.01 0.95 0.08 0.47 0.45 0.41 0.11 0.51 0.45
deepseek-r1-8b-qwen3 0.08 0.68 0.03 0.39 0.39 0.34 0.10 0.50 0.34
dolphin
dolphin3-8b-llama3.1 0.00 0.98 0.02 0.33 0.41 0.34 0.09 0.48 0.40
dolphin-mixtral-8x22b 0.00 1.00 0.15 0.57 0.42 0.43 0.04 0.49 0.26
dolphin-mixtral-8x7b 0.00 1.00 0.10 0.51 0.44 0.38 0.05 0.51 0.22
dolphin-phi-2.7b 0.00 0.91 0.11 0.41 0.40 0.40 0.02 0.57 0.11
falcon
falcon3-10b 0.00 1.00 0.05 0.45 0.45 0.42 0.06 0.46 0.33
falcon3-7b 0.00 0.98 0.04 0.47 0.39 0.42 0.05 0.43 0.31
gemini
gemini-2.5-flash-lite 0.00 1.00 0.02 0.31 0.41 0.34 0.11 0.45 0.41
gemini-2.5-flash 0.00 0.99 0.09 0.43 0.43 0.32 0.13 0.46 0.57
gemini-2.5-pro 0.00 1.00 0.24 0.50 0.44 0.36 0.17 0.48 0.66
gemma
gemma3-27b 0.00 1.00 0.08 0.33 0.42 0.36 0.09 0.45 0.40
gemma3-4b 0.00 0.94 0.08 0.35 0.43 0.37 0.07 0.45 0.36
gemma3n-e4b 0.00 0.99 0.18 0.38 0.45 0.41 0.08 0.45 0.36
gpt-oss
gpt-oss-120b <0.01 0.98 0.05 0.45 0.44 0.37 0.10 0.46 0.40
gpt-oss-20b 0.02 0.65 0.01 0.41 0.43 0.33 0.08 0.45 0.37
gpt-4
gpt-4.1 <0.01 1.00 0.08 0.36 0.41 0.36 0.13 0.49 0.49
gpt-4.1-mini 0.09 0.84 0.04 0.38 0.42 0.39 0.10 0.45 0.43
gpt-4.1-nano 0.29 0.69 0.05 0.40 0.42 0.41 0.06 0.46 0.43
llama
llama3.2-3b 0.00 0.98 0.02 0.35 0.42 0.34 0.10 0.47 0.35
llama3.3-70b 0.00 1.00 0.17 0.43 0.44 0.36 0.09 0.48 0.44
llama4-17b-maverick 0.00 1.00 0.26 0.44 0.44 0.36 0.10 0.51 0.45
llama4-17b-scout 0.00 1.00 0.13 0.34 0.43 0.31 0.10 0.47 0.37
mistral
mistral-7b 0.00 1.00 0.07 0.46 0.45 0.32 0.11 0.45 0.28
mistral-large-123b 0.10 0.87 0.11 0.53 0.45 0.39 0.12 0.50 0.44
mistral-nemo-12b 0.00 1.00 0.03 0.38 0.43 0.36 0.10 0.47 0.34
mistral-small-22b 0.00 1.00 0.04 0.48 0.43 0.37 0.11 0.49 0.33
mistral-small3.2-24b 0.00 1.00 0.43 0.42 0.46 0.38 0.13 0.50 0.43
mixtral
mixtral-8x22b 0.00 1.00 0.06 0.45 0.44 0.38 0.12 0.48 0.44
mixtral-8x7b 0.00 0.92 0.11 0.35 0.43 0.33 0.09 0.48 0.34
olmo
olmo2-13b 0.00 1.00 0.09 0.49 0.37 0.44 0.09 0.43 0.27
olmo2-7b 0.00 0.71 0.04 0.41 0.40 0.39 0.10 0.45 0.31
phi
phi4-14b 0.00 1.00 0.04 0.40 0.43 0.36 0.08 0.47 0.34
phi4-mini-3.8b 0.05 0.29 0.05 0.40 0.44 0.38 0.07 0.48 0.35
phi4-reasoning-14b 0.18 0.68 0.04 0.50 0.44 0.40 0.06 0.47 0.25
qwen
qwen3-235b-a22b 0.41 0.21 0.24 0.43 0.42 0.39 0.14 0.51 0.45
qwen3-32b <0.01 0.98 0.07 0.42 0.36 0.40 0.13 0.46 0.46
qwen3-8b <0.01 0.95 0.07 0.43 0.42 0.35 0.11 0.48 0.41
qwq
qwq-32b 0.51 0.08 0.13 0.45 0.35 0.37 0.12 0.43 0.34
smollm
smollm2-1.7b 0.00 0.57 0.01 0.38 0.48 0.41 0.05 0.48 0.16
yi
yi-34b 0.00 0.93 0.04 0.40 0.44 0.37 0.10 0.46 0.28
yi-9b 0.00 0.98 0.03 0.41 0.44 0.37 0.07 0.45 0.27
0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1 0 0.5 1